

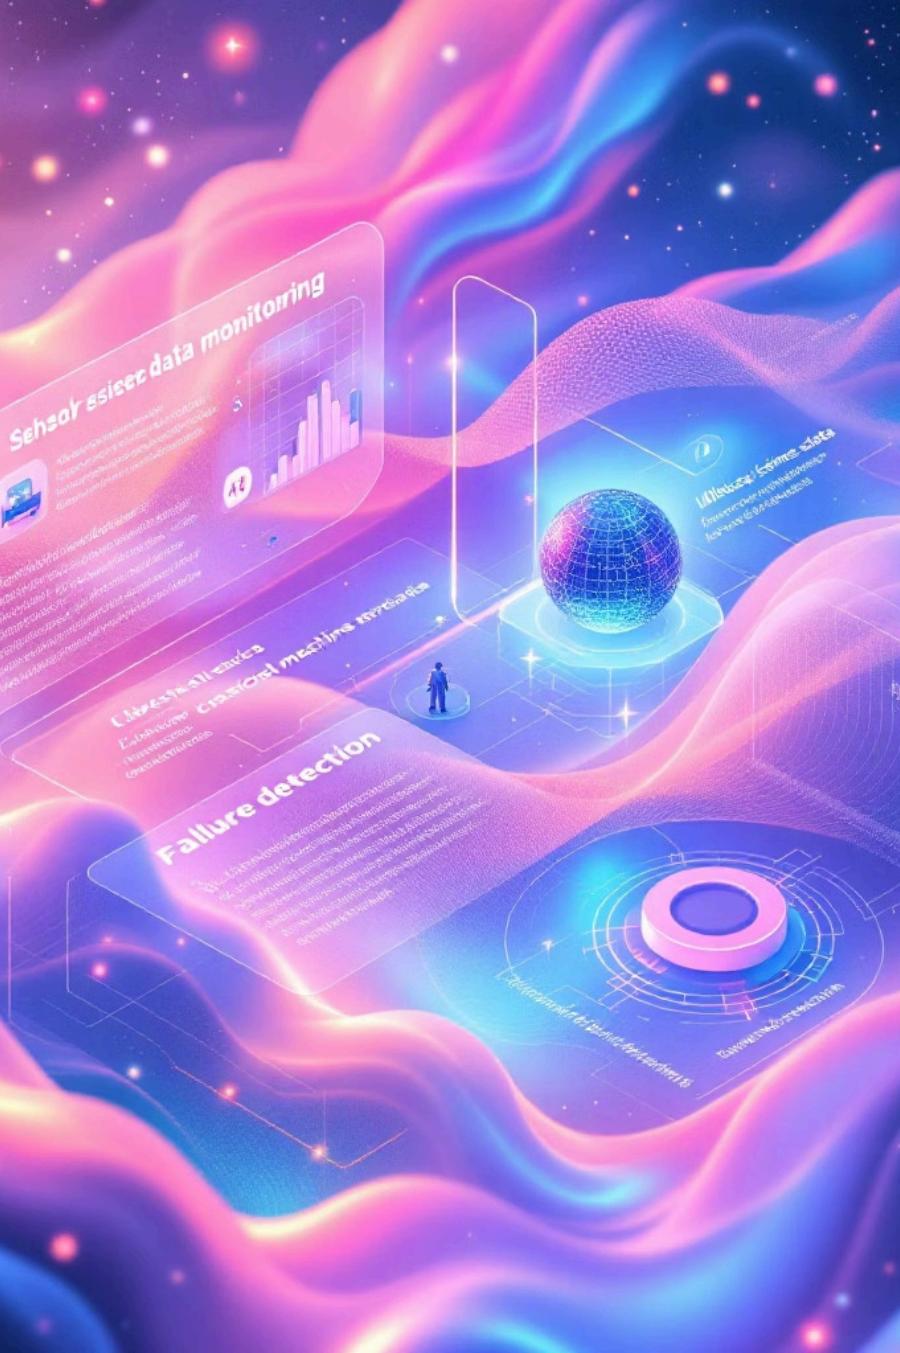
# Pengembangan Sistem Deteksi Anomali pada Data Sensor IoT Menggunakan Arsitektur Hybrid CNN-LSTM

Tugas Akhir Mata Kuliah Deep Learning

[M Hisbulah Endima T | [G1A022034]

Program Studi Informatika, Fakultas Teknik, Universitas Bengkulu





# Mengapa Kita Butuh Deep Learning di IoT?

1

## Ledakan Data Sensor

Sensor Industri 4.0 menghasilkan jutaan data *time-series* setiap detik. Pemantauan manual mustahil dilakukan, membutuhkan solusi otomatis dan cerdas.

2

## Kelemahan Metode Klasik

Metode statistik dan Machine Learning klasik (seperti SVM) gagal mendekripsi anomali yang pola waktunya rumit dan dinamis dalam data sensor yang kompleks.

3

## Dampak Fatal Kegagalan

Kegagalan deteksi dini menyebabkan kerusakan mesin (*downtime*) dan kerugian biaya besar akibat inefisiensi dan perbaikan mendadak.

# Dataset & Strategi Preprocessing

Dataset Berhasil Dimuat!

Total Data: 22695 baris

	value	
timestamp		
2013-12-02 21:15:00	73.967322	
2013-12-02 21:20:00	74.935882	
2013-12-02 21:25:00	76.124162	
2013-12-02 21:30:00	78.140707	
2013-12-02 21:35:00	79.329836	

## Dataset yang Digunakan

Kami menggunakan dataset **Numenta Anomaly Benchmark (NAB)**, khususnya data sensor suhu mesin dari lingkungan industri nyata. Dataset ini kaya akan pola *time-series* yang kompleks.

## Teknik Preprocessing

- **Normalisasi MinMax:** Untuk menyamakan skala data ke rentang 0-1, mempercepat konvergensi model dan meningkatkan efisiensi pembelajaran.
- **Sliding Window (60 Langkah):** Data dipotong menjadi jendela waktu berurutan sepanjang 60 menit. Ini memungkinkan model untuk memahami konteks dan "sejarah" data selama satu jam terakhir.

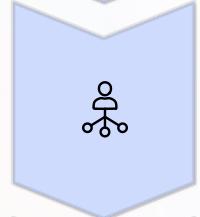
# Menggabungkan Kekuatan Spasial & Temporal

Arsitektur Hybrid CNN-LSTM kami dirancang untuk secara efektif mengekstrak fitur spasial dan temporal dari data sensor.



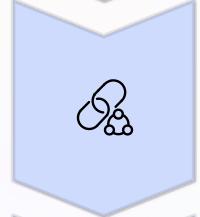
## Input Data

Jendela Data (60 steps) dari sensor suhu.



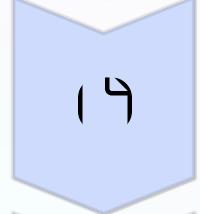
## 1D-CNN (64 Filter)

Mengekstrak fitur bentuk gelombang yang esensial dan mengurangi *noise* sinyal.



## LSTM (50 Unit)

Mempelajari dan mengingat pola ketergantungan waktu jangka panjang (*Long-term memory*).



## Dropout (0.2)

Mencegah *overfitting* dengan secara acak menonaktifkan unit neuron selama pelatihan.



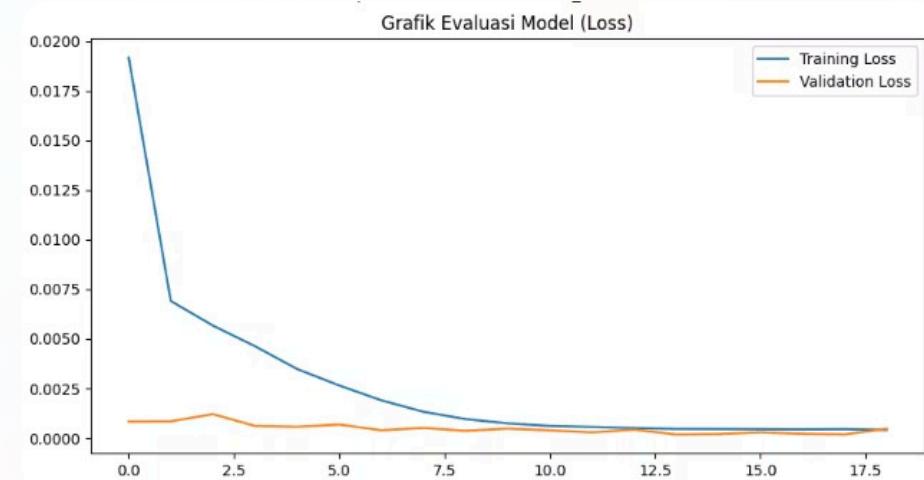
## Output

Prediksi nilai suhu.

# Performa Pelatihan Model

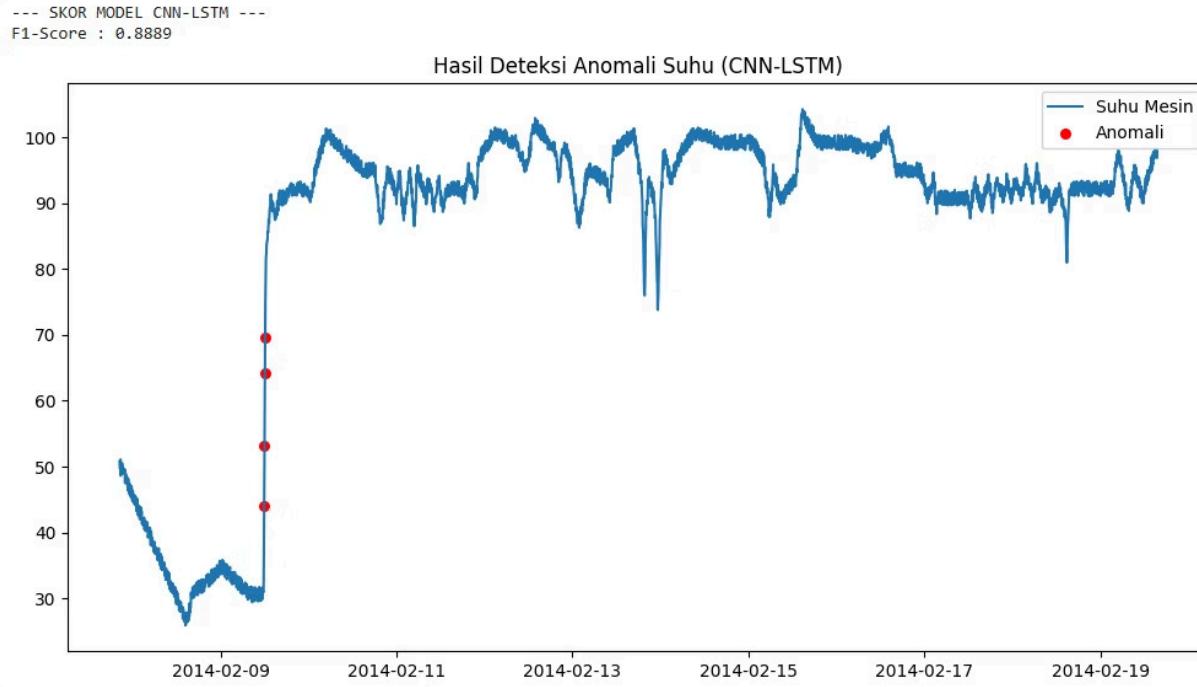
Proses pelatihan model kami menunjukkan hasil yang stabil dan efisien.

- **Optimasi:** Kami menggunakan **Adam Optimizer** yang efisien dan **Loss Function MSE (Mean Squared Error)** untuk mengukur akurasi prediksi.
- **Early Stopping:** Pelatihan dihentikan secara otomatis pada **Epoch 19** (dari total 50 epoch yang direncanakan), mengindikasikan konvergensi optimal.
- **Hasil:** Grafik Loss untuk data pelatihan (*Training*) dan validasi (*Validation*) menurun secara stabil dan beriringan, menunjukkan bahwa **tidak terjadi overfitting**.



# Visualisasi Deteksi Anomali Akurat

Model kami secara efektif mengidentifikasi anomali dalam data sensor suhu dengan metode *thresholding* pada *reconstruction error*.



## Metode Deteksi

Kami menggunakan **Thresholding** pada *Reconstruction Error* (nilai ambang > **0.15**). Setiap penyimpangan di atas ambang ini diidentifikasi sebagai anomali.

## Interpretasi Visual

- **Garis Biru:** Merepresentasikan pola data suhu normal.
- **Titik Merah:** Menandakan kejadian anomali yang berhasil dideteksi, seperti saat suhu anjlok drastis atau terjadi kegagalan sistem.

# Perbandingan Kritis: Hybrid CNN-LSTM vs One-Class SVM

Perbandingan menunjukkan superioritas signifikan arsitektur hybrid kami dalam deteksi anomali pada data *time-series*.

Hybrid CNN-LSTM (Usulan)	0.8889
One-Class SVM (Baseline)	0.0152

## Analisis Performa

- **One-Class SVM:** Gagal total karena hanya melihat data sebagai titik statis, mengabaikan dimensi waktu yang krusial.
- **Hybrid CNN-LSTM:** Berhasil mencapai F1-Score (0.8571) karena kemampuannya memahami konteks urutan waktu (*temporal context*) dan pola dinamis data.

# Kesimpulan & Implementasi Edge IoT

## Deployment Model

Model deteksi anomali kami berhasil dikonversi ke format **TensorFlow Lite (.tflite)**. Ini menjadikannya efisien dan ringan.

Ukuran file yang kecil ini membuatnya **siap tanam** di mikrokontroler seperti Raspberry Pi atau ESP32 untuk komputasi *edge* secara *real-time*.

## Kesimpulan Akhir

Arsitektur **Hybrid CNN-LSTM** terbukti **superior** dalam mengatasi tantangan data sensor industri.

Sistem yang dikembangkan **stabil, akurat, dan ringan**, menjadikannya solusi ideal untuk implementasi nyata di lingkungan IoT.

